

Segnali comunitari e moderazione ufficiale su Bluesky

Analisi predittiva e correlazionale · Marzo 2026

**I segnali comunitari
pubblici possono
anticipare la
moderazione ufficiale?**

CONTESTO

Bluesky, il social network

Bluesky è un social network simile a Twitter, ma progettato per essere più aperto e meno dipendente da una singola piattaforma centrale.

È costruito su **ATProto**, il protocollo tecnico che organizza il funzionamento della piattaforma: account, post, follows, blocchi, liste e labels sono gestiti secondo regole comuni e possono essere letti attraverso API pubbliche.

Per questo progetto, l'aspetto centrale è l'osservabilità: su Bluesky molte informazioni pubbliche — come blocchi, follows, liste e labels — possono essere raccolte e analizzate. Questo permette di studiare i segnali prodotti dagli utenti o da servizi indipendenti e confrontarli con le decisioni ufficiali di moderazione, come il ! takedown.

Fonti ufficiali:

AT Protocol docs — 

Bluesky's Moderation Architecture — 

Labels and moderation — 

Che cosa studia il progetto – domanda di ricerca

I segnali comunitari pubblici possono anticipare la moderazione ufficiale?

L'obiettivo è capire se, prima di una decisione ufficiale della piattaforma, emergano già segnali pubblici prodotti dalla comunità: tracce di attenzione negativa, classificazioni esterne o forme distribuite di moderazione. Questi segnali vengono poi confrontati con il "takedown" di un account da parte della moderazione ufficiale per valutarne il potere informativo.

Segnali comunitari pubblici

Tra i molti segnali osservabili su Bluesky, il progetto si concentra su quelli più rilevanti per la moderazione comunitaria: tracce pubblicamente osservabili prodotte dagli utenti o da servizi di moderazione non ufficiali

01 · Blocchi individuali

Sono azioni dirette tra utenti: un account decide di bloccarne un altro, impedendogli di interagire normalmente con lui e nascondendolo dall'esperienza dell'utente che blocca.

[Block implementation](#) 

02 · Modlist / blocklist

Sono liste di account usate per applicare un'azione di moderazione collettiva, come mute o block, non su un singolo profilo ma su un insieme di account. In pratica, un utente o una comunità può costruire una lista di account problematici, e altri utenti possono adottarla per bloccare o silenziare tutti gli account inclusi.

[User lists](#) 

[Graph API](#) 

03 · Labeler terzi

Sono servizi di moderazione indipendenti dal labeler ufficiale di Bluesky. Producono labels, cioè etichette applicate ad account, contenuti o altri oggetti del protocollo, secondo criteri propri. L'utente può scegliere di usare questi servizi come livello aggiuntivo di moderazione.

[Moderation docs](#) 

[Architecture](#) 

Stato dell'arte

Lavori vicini su Bluesky: architettura, blocking individuale e blocklist comunitarie

Lavoro	Che cosa tratta	Collegamento con questo progetto
Balduf et al. 2024	Looking at the Blue Skies of Bluesky Prima misura ampia della piattaforma: crescita, attività degli utenti, architettura ATProto e componenti gestibili da provider terzi. ACM DOI 	Base metodologica e infrastrutturale: definisce il contesto empirico e le strutture dati usate nei lavori successivi.
Bono et al. 2025	Self-moderation in the decentralized era Studia il blocking individuale su Bluesky: profili utente costruiti con feature di attività, contenuto e grafo; modelli per stimare chi viene bloccato. arXiv 	Vicino al nostro uso dei blocchi, ma l'evento di interesse resta "essere bloccati", non il takedown ufficiale.
Sokoto et al. City / London 2026	Open or Blocked Skies? Analizza blocchi e soprattutto blocklist: scala, categorie, utenti colpiti, criteri di lista e conseguenze sul grafo sociale. City Open Access 	Riferimento principale per le blocklist; mostra che sono centrali nella moderazione comunitaria, ma eterogenee e concentrate.

Dati disponibili

Che cosa contenevano i dati grezzi e in quale forma sono stati resi utilizzabili.

1 · Origine dei dati

File .parquet concessi dagli autori di "Looking at the Blue Skies of Bluesky", [Dataset Balduf](#)  costruiti a partire da stream API ATProto e **arricchiti con stream dai log del labeler ufficiale di Bluesky**. Il materiale di partenza è un insieme di file separati che descrivono profili, attività, interazioni e segnali di moderazione.

2 · Che cosa entra nell'analisi

Profili account con ID e data di creazione; **post** per misurare attività pubblica; **blocchi ricevuti** come segnale comunitario diretto; **liste/modlist** come segnale comunitario aggregato; **labels** del labeler ufficiale e di labeler terzi; **!takedown** come proxy dell'enforcement ufficiale account-level.

3 · Variabili derivate

Sui dati grezzi sono state costruite variabili derivate: conteggi nei 10 giorni pre-evento, numero di post, follow ricevuti, blocchi totali, unique blockers, blocchi giornalieri, presenza in modlist, labels osservate, età dell'account e classificazione in gruppi a seconda dell'esposizione di un account.

Strumenti software e metodo operativo

Come sono stati trattati i dati e quale unità analitica è stata costruita.

4 · Anonimizzazione

I dati non anonimizzati sono rimasti su macchina virtuale, perché contengono identificativi reali e metadati sensibili. Per il lavoro locale sono stati esportati solo dataset derivati e anonimizzati: i DID reali vengono sostituiti da DID anonimi tramite hashing deterministico; i file locali conservano variabili aggregate e non contenuti testuali o identità leggibili.

5 · Software

Python per script riproducibili; **DuckDB** per leggere e filtrare grandi file .parquet e .csv.gz senza caricarli integralmente in memoria; **pandas/numpy** per trasformazioni e controlli; **Jupyter Notebook** per analisi descrittive e grafici; **scikit-learn** per Random Forest.

6 · Unità di analisi

L'analisi è stata portata a livello account-evento. I casi positivi sono account con un !takedown ufficiale; i casi negativi sono account osservabili senza takedown, a cui viene assegnato uno pseudo-event_time nello stesso periodo. Per i negativi si verifica inoltre che nei 10 giorni successivi allo pseudo-evento non ricevano un takedown. Tutte le variabili sono calcolate prima dell'evento o pseudo-evento, così da chiedere se i segnali pubblici fossero già osservabili prima della decisione ufficiale.

Dataset analizzati

Numeri principali della base empirica usata.

INPUT GREZZI

Dati di partenza

1.222.452	DID distinti nei profili
4.189	file log labeler ufficiale
36.946.883	righe post 11-21 marzo
159.161	eventi !takedown in marzo
158.803	account positivi unici

DATASET OPERATIVO

Base account-evento

47.821 positivi account con !takedown nel periodo 11-21 marzo	366.515 negativi account osservabili senza takedown a marzo
---	---

Struttura finale

Unità	account-evento
Finestra segnali	10 giorni pre-evento
Osservazioni negative	4.031.665 account-giorno

i 366.515 account negativi vengono osservati per ciascuno degli 11 giorni della finestra operativa, dal 11 al 21 marzo, ottenendo $366.515 \times 11 = 4.031.665$ osservazioni negative

Pipeline dati e costruzione del dataset account-evento

1 Ispezione e selezione dati

Apro parquet e csv.gz con DuckDB/Python: schema, colonne, head, chiavi DID, timestamp e copertura temporale. Individuo quali file sono usabili: profili, post, logs del labeler, liste e blocchi.

2 Selezione Positivi

Estraggo account con label ufficiale account-level '!takedown' non-neg. Per ogni account uso il primo takedown come event_time T; per avere 10 giorni osservabili tengo gli eventi 11-21 marzo.

3 Selezione Negativi

Parto dagli account osservabili a marzo, creati prima del mese e senza takedown. A ciascuno assegno uno pseudo-event_time negli stessi giorni dei positivi, così il confronto non dipende dal calendario. **Gli account negativi** vengono osservati per ciascuno degli **11 giorni** della finestra operativa,

4 Finestra pre-evento

Per positivi e negativi guardo solo $[T-10 \text{ giorni}, T)$. In questa finestra calcolo attività, visibilità e segnali comunitari; per i negativi verifico anche che nei 10 giorni dopo T non gli venga assegnato il takedown.

5 Feature derivate

Costruisco conteggi account-level: post 10d, follow ricevuti, blocchi totali, unique blockers, blocchi giorno-per-giorno, presenza in modlist, labels ufficiali e di terzi.

6 Controllo per esposizione

Divido gli account in bucket lineari per post $\times$ follow ricevuti. . Questo separa gli utenti a seconda della loro esposizione sulla piattaforma.

7 Output finale e analisi

Dai dataset finali costruisco tabelle/grafici descrittivi, pool bilanciati e modelli Random Forest + SHAP.

Utility window: perché 10 giorni?

La finestra di osservazione pre-evento

Serve a calcolare solo segnali già osservabili prima della decisione ufficiale.



T è escluso: non entra informazione successiva al takedown.

T = primo !takedown per i positivi; pseudo-event_time per i negativi nello stesso giorno dei positivi.

Dentro la finestra: post, follow ricevuti, blocchi, unique blockers, labels e modlist.

Perché proprio 10 giorni

La scelta deriva dallo script `true_takedown_utility_window.py`: sui post pre-evento viene stimata la storia minima utile, poi si seleziona la finestra più piccola nella griglia candidata.

- 1 q80_i per account**
distanza che contiene l'80% dei post pre-evento
- 2 Q75(q80_i)**
soglia robusta tra account con storia sufficiente
- 3 griglia candidate**
scelta della finestra minima che supera la soglia

**Esito
operativo**

10 giorni

abbastanza lunga da catturare segnali recenti, abbastanza corta da non trascinare storia troppo lontana dal takedown.

Confronto a parità di esposizione

Per evitare confronti distorti, positivi e negativi vengono letti dentro gruppi con attività e visibilità simili.

Come ho reso comparabili gli account

- **Perché divido per esposizione:** un account molto attivo o molto seguito può ricevere più blocchi solo perché è più visibile. La divisione serve quindi a confrontare account davvero simili.
- **Variabili usate:** post pubblicati nei 10 giorni pre-evento e follow ricevuti dall'inizio della finestra fino allo (pseudo-)evento.
- **Cosa sono i bucket:** classi ordinate che trasformano post e follow in livelli di esposizione: 0 · 1 · 2 · 3-5 · 6-10 · 11-25 · 26-50 · 51-100 · 101-250 · 251-500 · 501-1000 · 1001+.
- **Cosa indicano:** non misurano il valore esatto, ma il livello di attività/visibilità dell'account prima dell'evento.
- **Corner:** dai due bucket ricavo quattro gruppi generali: 00 = 0 post/0 follower; 0p = 0 post/con follower; p0 = con post/0 follower; pp = con post/con follower. Questi gruppi verranno poi usati per distinguere account senza esposizione da account più osservabili.

RISULTATI PRINCIPALI EMERSI

Domanda operativa

- 1. Come si distribuiscono i positivi rispetto al livello di esposizione pubblica?

Risultato sintetico

→ 60,23% nel corner 00: 0 post e 0 follower.

- 2. I blocchi distinguono positivi e negativi?

→ Sì: positivi più bloccati nei 10 giorni pre-takedown.

- 3. Il segnale resta valido a parità di esposizione?

→ Sì: anche controllando post e follower, i positivi hanno più blocchi.

- 4. Quando emerge il segnale dei blocchi?

→ Soprattutto vicino a T: il giorno immediatamente precedente è il più informativo.

- 5. Il segnale cambia per tipo di account?

→ Sì: debole nel 00; cresce in 0p/p0 e soprattutto pp.

- 6. La Random Forest conferma il ruolo del corner 00?

→ Sì: $F1 \approx 0,38$ nel pool completo; $\approx 0,73$ senza 00.


- 7. Qual è il risultato dell'analisi principale?

→ No 00: CV $F1$ 0,688; test $F1$ 0,672 · test AUC 0,753; pp test AUC 0,821.

- 8. Labels e modlist sono segnali predittivi utili?

→ Poco: coverage bassa; labels post-level 2,34%, modlist 1,94% dei positivi.

Risultato 1.1 — Come si distribuiscono i positivi rispetto al livello di esposizione pubblica?




Corner	Negativi	Positivi
00 · 0 post / 0 follower	33,81%	60,23%
0p · 0 post / follower	10,43%	12,37%
p0 · post / 0 follower	17,21%	9,99%
pp · post / follower	38,55%	17,42%

Il punto non è solo quantitativo: il 60% dei positivi si trova in un gruppo dove i segnali pubblici dai noi osservati sono quasi assenti per definizione.

Il dataset dei positivi non è omogeneo

Risultato 1.2 — il corner 00 ha una dinamica propria

Non è semplice rumore: è una popolazione diversa di account



≈ 42 ore

Media lifetime nel corner 00



Gli account 00 vengono intercettati prima di accumulare segnali pubblici: non hanno post, non hanno follower e quasi mai ricevono blocchi osservabili.

Interpretazione coerente con account usa-e-getta, spam, ban evasion o altri pattern anti-abuso account-level.

Questa evidenza spiega perché il modello completo fatica: molti positivi non hanno il tempo di lasciare segnali comunitari.


Conseguenza metodologica: Nella successive analisi eventualmente separeremo il corner 00

Risultato 2 - I blocchi distinguono positivi e negativi?




Il grafico mostra che gli account poi sottoposti a takedown ricevono blocchi più spesso dei negativi. La differenza diventa più chiara quando si separa il corner 00, perché lì molti account vengono rimossi troppo presto per accumulare blocchi osservabili.

Risultato 3.1 — Il segnale resta valido a parità di esposizione?




A parità di post bucket: nei bucket bassi i positivi mostrano sia una probabilità più alta di ricevere almeno un blocco sia un numero medio di blocchi superiore. Nei bucket più alti la differenza sulla quota con almeno un blocco si riduce, perché anche i negativi più esposti ricevono blocchi. Tuttavia resta marcata la distanza sull'intensità media: i positivi non solo vengono bloccati, ma accumulano più blocchi.

Risultato 3.2 — Controllo congiunto per post e follower




Il grafico compara, confrontando per ogni bucket di esposizione, il rapporto tra blocchi dei positivi e blocchi dei negativi. Più il colore è intenso maggiore è significativo il segnale studiato. La zona più forte è nei bucket bassi e intermedi: soprattutto account con pochi post ma qualche follow ricevuto.

Risultato 4 — Quando emerge il segnale dei blocchi?



Il grafico mostra la dinamica dei blocchi nei 10 giorni prima dell'evento: -1 è il giorno più vicino al takedown. Nei negativi la probabilità e il numero medio di blocchi restano quasi piatti; nei positivi invece aumentano rapidamente negli ultimi 2-3 giorni. La parte centrale conferma che oltre metà del volume di blocchi dei positivi cade nell'ultimo giorno: il segnale è quindi anticipatorio, ma molto ravvicinato.

Risultato 5 — il segnale cambia per tipo di account?



Dopo aver visto che il segnale accelera vicino al takedown, qui lo separiamo per corner. Il risultato conferma che il corner 00 è quasi piatto, mentre nei gruppi 0p, p0 e soprattutto pp i positivi si distinguono dai negativi negli ultimi giorni.

Risultato 6.1 — analisi predittiva con Random Forest

Obiettivo dell'esperimento

Passare dal confronto descrittivo alla classificazione: usare solo segnali osservati prima di T per capire se un account assomiglia più a un positivo (!takedown) o a un negativo comparabile.

1 • Dataset account-evento

Una riga = un account osservato rispetto a un evento T o pseudo-evento.

2 • Feature pre-evento

Conteggi dei blocchi nei 10 giorni precedenti: totali, unique blockers e profilo giornaliero.

3 • Random Forest

Il modello combina molti alberi decisionali e "vota" la classe finale: positivo o negativo.

Controllo metodologico

Le variabili entrano nel modello solo se osservate prima dell'evento. In questo modo non si usa informazione successiva al takedown.

Perché più pool

La stessa idea viene provata su campioni bilanciati diversi: pool completo, pool senza corner 00 e gruppi 0p / p0 / pp.

Risultato 6.2 — come è costruito il test predittivo

Procedura usata nel notebook

- 1 Pool bilanciato**
Stesso numero di positivi e negativi: il modello non può “vincere” scegliendo sempre la classe più frequente.
- 2 Split 70/30 stratificato**
Il dataset viene diviso in training e test mantenendo la proporzione tra positivi e negativi.
- 3 Cross-validation sul training**
Sul training viene applicata StratifiedKFold: 5 fold nelle prove iniziali, 10 fold nell’analisi principale.
- 4 Metriche out-of-fold**
Le predizioni di CV producono Accuracy, Precision, Recall, F1, ROC AUC e matrice di confusione.

Che cosa impara la Random Forest

Non legge testo o profili: usa solo numeri sui blocchi ricevuti prima di T. Se pattern simili compaiono più spesso nei positivi, il modello li usa per classificare nuovi casi.

Che cosa viene confrontato

Prestazioni globali e prestazioni per macro-gruppo. Questo serve a verificare se il segnale funziona davvero nei gruppi esposti e se il corner 00 distorce il modello.

Cosa produce l’esperimento

Non una spiegazione causale, ma una misura predittiva: quanto i blocchi pre-evento separano account poi rimossi e account non rimossi.

Risultato 6.3 — setup testati nella Random Forest

Setup	Pool	Bilanciamento	Corner	CV F1	Lettura
A	1.000+1.000	corner proporzionali	00 incluso	0,382	campione piccolo: precision alta, recall bassa
B	~10.000+10.000	proporzionale	00 incluso	0,377	aumentare N non risolve se resta 00
C	~10.000+10.000	proporzionale	no 00 / bucket adiacenti	0,728	salto netto: il segnale blocchi emerge
D	10.000+10.000	4 corner bilanciati	00, 0p, p0, pp	0,563	media tra gruppo 00 debole e gruppi esposti
E	max 28.650	3 corner bilanciati	no 00: 0p, p0, pp	0,688	analisi principale: massima scala, gruppi comparabili

CV F1 = media dell’F1 nella cross-validation:
unisce precision e recall e riduce la
dipendenza da un solo split.

Lettura del confronto

La performance cambia soprattutto con la costruzione del campione: quando il corner 00 resta dentro, il segnale dei blocchi viene attenuato; quando viene escluso, emerge il salto più netto.

Risultato 7.1 — analisi principale: setup e metriche globali

SETUP

- Dataset totale: 28.650 osservazioni
- Target: positivo = account con ! takedown; negativo = controllo senza takedown
- Corner: 00 escluso; 0p, p0, pp bilanciati
- Feature usate: unique blockers totali e giornalieri nella finestra 10d
- Modello: Random Forest, 1.000 alberi, min_samples_leaf = 5

VALIDAZIONE

Split 70/30: il 70% va nel training, il 30% resta test. Sul training applico StratifiedKFold 10-fold: il modello viene riaddestrato su 10 divisioni diverse mantenendo bilanciate le classi. Le metriche CV sono calcolate out-of-fold sul training; dopo il fit finale, le metriche finali sono calcolate sul test held-out.

CV F1

0,688

Test Accuracy

0,739

Test Precision

0,841

Test Recall

0,559

Test ROC AUC

0,753

Confusion matrix test

	Pred. neg	Pred. pos
Vero neg	9035	992
Vero pos	4252	5776


Come leggere il risultato

Precision alta anche sul test (0,841): quando la RF classifica un account come positivo, spesso è davvero un account che riceverà takedown.

Recall moderata anche sul test (0,559): una parte dei positivi non viene intercettata perché non accumula abbastanza blocchi visibili.

Test ROC AUC 0,753: il modello separa le due classi meglio del caso, ma non in modo completo.

Risultato 7.2 — performance per corner esposto




Il gruppo pp è il più classificabile anche sul test held-out: AUC 0,821 e F1 positivi 0,745. Qui l'account ha sia post sia follower, quindi può accumulare blocchi osservabili.

Nei gruppi 0p e p0 il modello mantiene precision molto alta sui positivi, ma recall più bassa: segnala meno account, però quando segnala tende ad avere ragione.

Conclusione: escluso il 00, il segnale blocchi è informativo in tutti i gruppi, ma cresce con l'esposizione pubblica dell'account.

Gruppo	N train	Accuracy	ROC AUC	F1 positivi	Precision pos	Recall pos
0p	6.656	0,721	0,726	0,630	0,923	0,479
p0	6.768	0,738	0,748	0,660	0,927	0,512
pp	6.631	0,757	0,819	0,754	0,773	0,736

Risultato 7.3 — quali variabili guidano la Random Forest?



Come è ottenuta

Dopo il training, la Random Forest assegna a ogni feature un peso: quanto quella variabile contribuisce a separare positivi e negativi nelle split degli alberi. I pesi sono normalizzati a somma 1.

La feature dominante è `n_unique_blockers_day_0`: i blockers unici nel giorno immediatamente precedente all'evento spiegano da soli circa il 44% dell'importanza.

Interpretazione: non conta solo “avere tanti blocchi” nella finestra, ma la concentrazione ravvicinata del segnale. Il giorno –1 pesa molto più dei giorni lontani.

Risultato 8 - Altri segnali: labels e modlist

Lift talvolta alto, ma copertura troppo bassa per uso predittivo sistematico

Segnale	Coverage positivi	Lift / nota
Labels ufficiali post-level	2,34%	coverage bassa
Skywatch Blue account-level	2,944%	lift 4,24×
Profile Labeller account-level	1,913%	lift 12,36×
Blacksky Moderation account-level	0,090%	lift 14,27× ma quasi nullo
Modlist	1,943%	73 modlist coinvolte

Conclusione comune: segnale potenzialmente informativo, ma troppo rarefatto per sostenere la predizione.

Fallimento operativo, non teorico

Alcuni segnali hanno lift alto, quindi non sono "inutili". Il problema è la densità: compaiono su troppi pochi account per sostenere predizione sistematica.

Conseguenza

Nel deck e nell'analisi predittiva principale labels e modlist restano risultati di contesto, non variabili centrali.

Risultato negativo importante

La comunità reagisce soprattutto via blocchi individuali osservabili; le infrastrutture più aggregate sono troppo rarefatte nella finestra pre-takedown.

- **Coverage** = quanti positivi hanno quel segnale nella finestra pre-evento.
- **Lift** = quanto il segnale è più frequente nei positivi rispetto ai negativi.
- **Lift > 1** = segnale concentrato nei positivi.
- **Problema:** lift alto $\neq$ segnale utile, se la coverage è troppo bassa.

Sì, ma solo in modo parziale e condizionato.

I segnali comunitari pubblici anticipano il takedown quando l'account è visibile alla comunità. Non spiegano, invece, i takedown rapidissimi degli account senza esposizione pubblica.

Take-away centrale

La moderazione comunitaria anticipa una parte dell'enforcement ufficiale, ma solo per gli account che hanno avuto tempo di accumulare segnali pubblici.

0,688

CV F1 analisi
principale

no 00 · 0p/p0/pp

0,753

ROC AUC test

separazione sopra il
caso

0,821

AUC test nel gruppo
pp

post + follower

Blocchi ricevuti

Segnale più robusto: alta precisione, recall moderata, informazione concentrata nel giorno prima del takedown.

Corner 00

60,23% dei positivi: 0 post e 0 follower. Qui il segnale comunitario non ha il tempo di formarsi.

Labels e modlist

Lift talvolta elevato, ma coverage troppo bassa: 2,34% labels post-level; 1,94% modlist.


DISCUSSIONE

La chiave interpretativa: due regimi di takedown

Il risultato non è “i blocchi predicono tutto”. Il punto è che i takedown account-level mescolano due popolazioni diverse.

REGIME A — account esposti


Post e/o follower generano esposizione pubblica. Qui i blocchi possono accumularsi e diventare segnale predittivo.



Evidenza: AUC pp test = 0,821 · F1 positivi pp test = 0,745

REGIME B — account 00 / usa-e-getta

0 post, 0 follower, vita mediana prossima a zero: l'enforcement arriva prima della reazione comunitaria.



Conseguenza: mescolare i due regimi attenua il segnale dei blocchi e abbassa la performance.

DISCUSSIONE

Cosa predicono davvero i blocchi

Predizione ravvicinata, ad alta precisione, ma non completa.

0,841

Precision

quando segnala positivo,
spesso ha ragione

0,559

Recall

non cattura tutti i positivi

≈44%

Importanza day_0

unique blockers nell'ultimo
giorno

Dove funziona meglio

Gruppo pp: account con post e follower. È la popolazione più osservabile e quindi quella in cui il segnale dei blocchi è più leggibile.

AUC test 0,821 · F1 positivi test 0,745

Temporalità del segnale



Il segnale non è una previsione lunga: si concentra negli ultimi 1-3 giorni prima dell'enforcement.

Lettura corretta: i blocchi non dimostrano causalità. Misurano un segnale pre-evento che separa positivi e negativi meglio del caso, soprattutto negli account esposti.

DISCUSSIONE

Limiti e prossimi passi

Non tutti i segnali osservabili sono utili per predire: alcuni sono troppo rari nella finestra pre-evento.

Labels e modlist: perché non entrano al centro del modello

Segnale	Coverage	Nota
Labels ufficiali post-level	2,34%	coverage bassa
Modlist / blocklist	1,94%	troppo rarefatte
Skywatch Blue acc.	2,94%	lift 4,24×
Profile Labeller acc.	1,91%	lift 12,36×
Blacksky acc.	0,09%	lift alto, quasi nullo

Risultato: lift alto non basta se i casi osservabili sono pochi.

Limiti della lettura

Marzo 2026: finestra temporale limitata.
Analisi predittiva e correlazionale, non causale.
Corner 00 da trattare come popolazione separata.

Sviluppi futuri

- Estendere l'analisi a più mesi, per verificare la stabilità dei risultati nel tempo e controllare stagionalità o campagne di spam.
- Modellare direttamente la probabilità di takedown nelle ore successive, trasformando l'analisi in una previsione temporale ravvicinata.

il contributo non è mostrare che tutti i takedown siano prevedibili, ma distinguere quali takedown lasciano segnali comunitari e quali avvengono prima che quei segnali possano formarsi.

Fonti e materiali usati nel lavoro

Fonti esterne verificabili e artefatti analitici effettivamente usati; i link sono incorporati nei titoli.

1 · Fonti ufficiali Bluesky / ATProto

- 01

AT Protocol docs
Struttura ATProto, oggetti pubblici, account/post e API.
- 02

Bluesky Moderation Architecture
Moderazione componibile: servizio ufficiale, labeler terzi e controlli utente.
- 03

Labels and moderation docs
Definizione tecnica di labels, labeler e applicazione a record/account.
- 04

Block implementation + User Lists
Blocchi individuali, liste utente e modlist come segnali comunitari.
- 05

Transparency Reports 2023 / 2025
Spam, impersonation, ban evasion ed enforcement account-level.

2 · Letteratura scientifica

- 01

Balduf et al. 2024 — Blue Skies of Bluesky
Analisi larga scala: architettura, dataset e stream ATProto.
- 02

Bono et al. 2025/2026 — Self-moderation on Bluesky
Blocking behavior: feature di attività/grafico e predizione del blocco.
- 03

Sokoto et al. 2026 — Open or Blocked Skies?
Blocklist/modlist: scala, categorie, account colpiti e impatto sul grafico.

3 · Materiali analitici del progetto

Non sono fonti bibliografiche: sono gli artefatti che producono metriche, grafici e risultati riportati nel deck.

blocks_signal_v3.ipynb Blocchi: distribuzioni, timing, corner, grafici.	rf_and_shap_on_blocks.ipynb Random Forest: setup, metriche, feature importance.	true_takedown_utility_window.py Utility window: scelta dei 10 giorni.
---	---	---